

Trabalho 3

Aplicações com LLMs, RAG e Validação

Disciplina: Inteligência Artificial

Versão para divulgação aos alunos

Apresentação

Bem-vindos(as) ao terceiro grande desafio prático da disciplina de Inteligência Artificial.

Neste trabalho, o foco será o desenvolvimento de uma aplicação baseada em modelos de linguagem, mas com um cuidado importante: não basta enviar um texto para um LLM e exibir a resposta. O objetivo aqui é construir uma solução mais completa, que envolva recuperação de contexto, ingestão de documentos, vetorização, armazenamento vetorial, validação e análise crítica dos resultados.

Ao longo das aulas, discutimos que LLMs podem ser muito úteis, mas também podem produzir respostas frágeis, imprecisas ou simplesmente erradas. Por isso, aplicações reais precisam ir além do prompt. Elas exigem projeto, critérios técnicos e mecanismos que reduzam respostas mal fundamentadas.

A proposta deste trabalho é justamente essa: fazer com que cada grupo desenvolva uma aplicação com LLM que utilize uma base externa de conhecimento, implemente um pipeline de RAG e apresente evidências experimentais sobre o que funciona bem, o que falha e por quê.

Como nos trabalhos anteriores, ética e transparência continuam valendo em todas as etapas. Ferramentas de IA generativa podem ser usadas como apoio, mas não substituem o entendimento do grupo. Toda decisão relevante deve ser compreendida e defendida por vocês na apresentação oral.

Objetivos de aprendizagem

- Construir uma aplicação com LLM que vá além da simples geração direta de texto.
- Organizar uma base documental para servir como fonte externa de conhecimento.
- Implementar um processo de ingestão com segmentação em chunks, vetorização e armazenamento vetorial.
- Utilizar recuperação vetorial para fornecer contexto relevante ao modelo.
- Empregar mecanismos de validação, estruturação de saída ou regras complementares para melhorar a confiabilidade da aplicação.
- Planejar e executar uma avaliação experimental comparando diferentes versões da solução.
- Analisar criticamente falhas, limitações e comportamentos problemáticos do sistema.
- Comunicar com clareza a arquitetura da aplicação, os experimentos realizados e as conclusões obtidas.

Organização da turma

A turma será organizada em 6 grupos.

Neste trabalho, teremos 3 temas de projeto, com 2 grupos trabalhando em cada tema. O sorteio dos temas será feito em sala.

Dois grupos trabalharão sobre o mesmo tema, mas isso não significa que os trabalhos devam ser parecidos. Cada grupo deverá construir sua própria base documental, fazer suas próprias escolhas de ingestão, recuperação, validação e avaliação, além de apresentar sua própria análise crítica.

Trabalhos excessivamente semelhantes entre si serão analisados com atenção especial.

Ideia geral do trabalho

Cada grupo deverá desenvolver uma aplicação com LLM que obrigatoriamente inclua:

- uso de um modelo de linguagem;
- uso de uma base externa de conhecimento;
- ingestão documental com chunking;
- geração de embeddings;
- armazenamento vetorial persistente;
- recuperação vetorial de contexto;
- algum mecanismo de validação, estruturação de saída ou lógica híbrida;
- avaliação experimental com comparação entre versões da solução.

Não será aceito como suficiente

- Receber texto do usuário, enviar esse texto para um LLM e devolver a resposta sem qualquer contexto externo, validação ou avaliação.
- Construir apenas um chat simples sem pipeline de ingestão, recuperação ou análise de resultados.

Temas disponíveis

Projeto 1: Assistente de consulta fundamentada sobre base documental – Grupos 3 e 5

Neste tema, o grupo deverá construir uma aplicação capaz de responder perguntas com base em um conjunto de documentos selecionado e preparado pelo próprio grupo.

A aplicação deve recuperar trechos relevantes antes da geração da resposta, responder com base no contexto recuperado, indicar quais trechos ou fontes sustentam a resposta e reconhecer quando a base não for suficiente para responder com segurança.

Exemplos de domínio: regulamentos, documentação técnica, normas públicas, manuais, editais e guias institucionais.

O foco aqui não é apenas responder bem, mas responder de forma fundamentada.

Projeto 2: Extrator estruturado com LLM e validação - Grupos 4 e 6

Neste tema, o grupo deverá construir uma aplicação que receba documentos ou textos e produza uma saída estruturada, com campos bem definidos, utilizando LLM e mecanismos de validação.

A aplicação deve receber um texto ou documento, extrair informações relevantes em formato estruturado, validar se os campos obrigatórios foram produzidos corretamente, tratar casos de resposta incompleta ou inválida e, quando fizer sentido, recorrer à base externa para apoiar normalização, classificação ou checagem.

Exemplos de domínio: editais, notícias, documentos administrativos, descrições de produtos, textos institucionais e documentos acadêmicos.

O foco aqui é mostrar que aplicações com LLM não precisam gerar apenas texto livre. Elas podem produzir saídas verificáveis e úteis para sistemas maiores.

Projeto 3: Sistema híbrido de triagem e recomendação com base documental – Grupos 1 e 2

Neste tema, o grupo deverá construir uma aplicação que receba uma solicitação do usuário, classifique o pedido, recupere contexto documental relevante e devolva uma resposta estruturada ou orientativa.

A aplicação deve combinar pelo menos LLM, recuperação vetorial e uma camada adicional de validação, regras ou lógica híbrida.

Exemplos de domínio: triagem de dúvidas frequentes, categorização de solicitações, orientação inicial para procedimentos, recomendação de encaminhamento e organização de pedidos por tipo e prioridade.

O foco aqui é mostrar que uma aplicação com LLM pode ser parte de um fluxo mais estruturado, e não apenas um gerador de resposta livre.

Requisitos técnicos mínimos

1. Base documental

Cada grupo deverá construir sua própria base documental.

Essa base deve ter volume suficiente para justificar um pipeline real de ingestão e recuperação. Como referência, espera-se algo como:

- 📄 pelo menos 15 documentos curtos; ou
- 📄 pelo menos 40 páginas equivalentes; ou
- 📄 pelo menos 80 chunks gerados ao final da ingestão.

Se o grupo optar por um volume menor, deverá justificar muito bem essa escolha.

2. Ingestão

O grupo deverá implementar e explicar claramente:

- 📄 como os documentos foram carregados;

- como foram segmentados;
- qual estratégia de chunking foi usada;
- se houve ou não overlap;
- e por que essas escolhas fazem sentido para o problema.

3. Embeddings

O grupo deverá informar:

- qual modelo de embedding utilizou;
- se ele pertence ao mesmo fornecedor do LLM ou não;
- e por que essa escolha foi feita.

4. Banco vetorial persistente

O armazenamento vetorial deve ser persistente. Não será suficiente manter tudo apenas em memória.

Exemplos aceitos incluem PostgreSQL com extensão pgvector, Chroma com persistência em disco, Qdrant, FAISS com persistência ou outra solução equivalente, desde que justificada.

5. Recuperação vetorial

A aplicação deve recuperar contexto documental relevante antes da geração da resposta final.

O grupo deve explicar, no mínimo:

- como a consulta foi vetorizada;
- como a similaridade foi usada;
- quantos trechos foram recuperados;
- e como os trechos foram incorporados ao prompt ou ao fluxo da aplicação.

6. Validação, estruturação ou mecanismo híbrido

A aplicação deve incluir pelo menos uma destas estratégias:

- saída estruturada em JSON ou formato equivalente;
- validação de campos obrigatórios;
- checagem por regras;
- recusa explícita quando o contexto for insuficiente;
- indicação de fontes ou trechos usados;
- camada híbrida com lógica complementar.

7. Comparação entre versões

Cada grupo deverá comparar pelo menos duas versões da sua solução.

Exemplos: LLM direto vs. LLM com RAG; RAG sem validação vs. RAG com validação; uma estratégia de chunking vs. outra; um valor de top-k vs. outro; um modelo de embedding vs. outro.

8. Avaliação experimental

Cada grupo deverá montar um conjunto de testes com pelo menos 30 casos.

Esse conjunto deve incluir, sempre que fizer sentido:

- casos fáceis;
- casos medianos;
- casos ambíguos;
- casos em que a base é insuficiente;
- casos que testem robustez e limites da aplicação.

Estrutura do trabalho e entregáveis

1. Relatório escrito, em PDF

O relatório deve conter, pelo menos, os seguintes itens:

- Definição do problema.
- Base documental.
- Pipeline de ingestão.
- Arquitetura da solução.
- Modelos e componentes utilizados.
- Protocolo experimental.
- Resultados.
- Análise crítica.
- Conclusão.
- Referências.

2. Código-fonte

O grupo deverá entregar um diretório contendo todos os arquivos necessários para executar a aplicação, instruções claras de instalação e execução, arquivo de dependências, arquivo `.env.example` quando necessário, sem expor segredos, e scripts, notebooks ou frontend utilizados.

O código deve estar organizado e legível.

3. Slides da apresentação

Cada grupo deverá entregar os slides que serão usados na apresentação oral.

4. Apresentação oral com demonstração

Cada grupo terá no máximo 20 minutos para apresentar.

Durante a apresentação, o grupo deverá mostrar:

- o problema atacado;
- a arquitetura da solução;
- a base documental;
- o pipeline de ingestão;
- a recuperação vetorial;
- a validação ou mecanismo híbrido;
- os resultados experimentais;
- e as principais falhas encontradas.

Além da demonstração preparada pelo grupo, poderá haver pelo menos uma consulta sugerida na hora pelo professor ou pelos colegas.

Todos os integrantes devem estar preparados para responder perguntas.

Critérios de avaliação

A nota deste trabalho seguirá a distribuição abaixo:

Critério	Pontuação
Qualidade da base documental e da ingestão	1,5
Chunking, embeddings e recuperação vetorial	1,0
Validação, estruturação de saída ou mecanismo híbrido	1,0
Protocolo experimental e comparação entre versões	1,0
Análise crítica dos resultados e falhas	1,5
Código-fonte e reprodutibilidade	1,0
Apresentação oral, demonstração e arguição	2,0
Participação crítica nas apresentações dos colegas	1,0

Total: 10,0 pontos.

Participação crítica nas apresentações dos colegas

Os grupos que estiverem assistindo às apresentações também serão avaliados.

Ao final de cada dia de apresentação, cada grupo da plateia deverá entregar uma ficha curta contendo:

- 🎬 pelo menos uma observação técnica relevante sobre uma apresentação assistida;
- 🎬 pelo menos uma pergunta pertinente feita ou que poderia ser feita;
- 🎬 pelo menos uma comparação entre a solução observada e o próprio trabalho do grupo.

Além disso, em cada apresentação, um grupo da plateia poderá ser sorteado para fazer a primeira pergunta.

A ideia é simples: assistir à apresentação dos colegas também faz parte do trabalho e também faz parte da aprendizagem.

Uso de IA generativa

Ferramentas de IA generativa podem ser usadas como apoio, por exemplo para discutir alternativas de implementação, revisar redação, sugerir estrutura de código ou apoiar testes e documentação.

No entanto, o grupo continua responsável por tudo o que entregar.

Não basta o sistema funcionar. É necessário compreender a arquitetura, a ingestão, a recuperação, a validação, os experimentos e os resultados.

No relatório, o grupo deverá incluir um item curto informando se utilizou ou não ferramentas de IA generativa, em que etapas elas foram usadas e que tipo de revisão ou validação humana foi feita.

Observações finais

Este trabalho foi pensado para exigir mais do que uma integração superficial com LLM.

Espera-se que cada grupo entregue uma solução que demonstre compreensão real dos conceitos apresentados em sala, capacidade de pesquisa e implementação, cuidado com avaliação e maturidade para discutir limites e falhas da própria solução.

Em aplicações com LLM, a parte mais fácil costuma ser fazer a chamada ao modelo. A parte mais importante é projetar bem o sistema ao redor dele.