

Extrator Estruturado com LLM, RAG e Validação

Projeto 2 — extrator genérico com LLM, RAG
e validação em camadas, aplicável a qualquer
PDF ou texto

Definição do Problema

- Uma aplicação que recebe qualquer PDF ou texto bruto — editais, notícias, relatórios, documentos administrativos — e devolve campos estruturados e validados, no lugar de texto livre.
- RAG entra como apoio: ingestão, embeddings e recuperação ajudam a normalizar, classificar e checar a extração.
- A extração estruturada continua sendo a tarefa principal — o RAG nunca vira resposta livre sem validação.

Base Documental

A extração funciona sobre qualquer documento enviado no momento — esta base é o conhecimento externo que o RAG usa como apoio, para normalizar, classificar e checar o que foi extraído.


- Relatório da CPMI dos atos de 8 de janeiro de 2023: linguagem institucional, depoimentos, órgãos públicos, pessoas, datas e fatos distribuídos em várias seções.
- Volume justifica ingestão, vetorização e recuperação semântica real — não um chat direto sobre o texto.
- Domínio favorece dois testes: localizar trechos e citar páginas (RAG), e identificar tipo, atores, datas e fatos (extração).

1.333

páginas · ~2,1M caracteres

Arquitetura da Solução

Hexagonal — portas e adaptadores (Python 3.12 + FastAPI)



Endpoints da API

Quatro rotas HTTP cobrem todo o fluxo, do envio do documento ao status da base

POST /api/ingest	Recebe um PDF, extrai, segmenta em chunks, gera embeddings e grava no pgvector.
------------------	---

POST /api/extract	Recebe PDF, texto bruto ou ambos e devolve os campos estruturados, validados e com fontes.
-------------------	--

POST /api/query	Pergunta em linguagem natural sobre a base já ingerida, com resposta e páginas-fonte.
-----------------	---

GET /api/health	Status da base vetorial: quantidade de chunks armazenados e conexão com o LLM.
-----------------	--

Modelos e Componentes

Provider-agnostic: o mesmo SDK openai fala com qualquer endpoint compatível

LLM · texto

Ollama (padrão)	phi4-mini
OpenAI	gpt-4o-mini etc.
Gemini / Groq / Together	compatível

Embeddings · vetores

openai (padrão)	768d · nomic-embed-text
spacy	300d · pt_core_news_lg

Cada embedder grava em sua própria tabela (chunk / chunk_spacy) — comparação justa, sem misturar dimensões.

Pipeline de Ingestão

Rota POST /api/ingest

1

PyMuPDF

Extraí texto página por página do PDF enviado

2

Chunking

RecursiveCharacterTextSplitter · 2000 caracteres, overlap 200

3

Embeddings

Um vetor por chunk, gerado pelo embedder escolhido

4

pgvector

Armazenamento vetorial persistente no PostgreSQL

Chunks curtos separavam atores, fatos e justificativas do mesmo contexto discursivo — o overlap mantém a continuidade entre fronteiras.

Recuperação Vetorial

Rotas POST /api/query e POST /api/extract

- A pergunta vira vetor e o pgvector busca os trechos mais próximos por distância de cosseno.
- Os trechos recuperados entram no prompt; o LLM responde e informa as páginas usadas como fonte.
- Em `api/extract`, o mecanismo `pgvector` apoia a normalização quando `top_k > 0`.

PERGUNTA

O relatório menciona Jair Bolsonaro?

FONTES CITADAS

Página 486 · Página 1281

Extração Estruturada e Validação

Rota POST /api/extract — validação em camadas

json.loads



reparo via LLM



fallbacks
determinísticos



validação Pydantic

Campos obrigatórios

document_type · title · main_event · facts

Status de saída

valid

partial

invalid

```
{
  "document_type": null,
  "title": null,
  "main_event": null,
  "dates": [],
  "actors": [],
  "organizations": [],
  "facts": [],
  "evidence": [],
  "categories": [],
  "sources": [{"claim": "string", "page": 0}],
  "confidence": "baixa"}
```

VALIDAÇÃO

Resultado estruturado

valid

confiança baixa

CONTEXTO

5 chunks

EMBEDDER

openai

FONTES

report.pdf

TIPO

relatorio

TÍTULO

Relatório: T3 IA

EVENTO PRINCIPAL

Criação de uma aplicação RAG para retornar output estruturado, com mecanismos de validação.

ATORES

Brunna Moura, Carlos Cruz,
Rafael Queiroz

ORGANIZAÇÕES

CPMI

— 06 · DEMONSTRAÇÃO

Interface Web

- Uma ação principal — Ingerir e extrair PDF — que chama ingest e extract com o mesmo arquivo.
- Resultado mostra status de validação, confiança, campos extraídos, fontes e chunks usados como contexto.
- Área secundária permite consultar a base vetorial já ingerida.
- Exemplo ao lado: extração rodada sobre o próprio relatório da equipe — o extrator funciona sobre qualquer PDF ou texto.

Protocolo Experimental

30 casos de teste · comparação entre $\text{top}_k = 5$ e $\text{top}_k = 15$

6

casos fáceis

7

casos médios

6

casos ambíguos

6

base insuficiente

5

limites da aplicação

Pontuação binária: 1 para resposta correta, 0 para incorreta ou insuficiente.

Resultados Experimentais

CATEGORIA	TOP_K = 5	TOP_K = 15
Casos fáceis	3 / 6	3 / 6
Casos médios	4 / 7	6 / 7
Casos ambíguos	3 / 6	2 / 6
Base insuficiente	5 / 6	6 / 6
Limites da aplicação	5 / 5	5 / 5
Total	20 / 30	23 / 30

Mais contexto ajudou nos casos médios e na base insuficiente, mas piorou os ambíguos — trechos concorrentes dificultam a resposta.

Análise Crítica

O que funcionou

- Testes cobrem chunking, extração, validação, repositório e rotas HTTP.
- Validação em camadas + reparo automático reduzem falhas de JSON malformatado.
- Recuperação ajuda quando a informação está dispersa no documento.

Limitações e falhas

- spaCy usa vetores estáticos e capta menos contexto semântico que modelos Transformer.
- Mais top_k ajuda casos médios, mas introduz trechos concorrentes nos ambíguos.
- Campos como facts e evidence ainda exigem revisão manual em documentos longos.

Conclusão

- Entrega completa: LLM, base documental externa, ingestão, embeddings, armazenamento vetorial, extração estruturada e validação.
- A arquitetura em portas e adaptadores facilita trocar embedders e provedores de LLM sem reescrever o domínio.
- Próximo passo: avaliar a extração campo a campo, com métricas de completude e comparação entre embedders.

— EQUIPE 4 · PROJETO 2

Perguntas?

Extrator Estruturado com LLM, RAG e Validação — relatório, código e slides disponíveis para consulta.